INFORME DE GUÍA PRÁCTICA

I. PORTADA

Tema:	Clasificación de dígitos manuscritos con MNIST
Unidad de Organización Curricular:	_____
Nivel y Paralelo:	_____ / _____
Alumnos participantes:	_____
	_____
Asignatura:	Inteligencia Artificial
Docente:	Rubén Nogales

II. INFORME DE GUÍA PRÁCTICA

2.1 Objetivos

General: Comparar el desempeño de un árbol de decisión, Random Forest y k-NN al clasificar dígitos manuscritos de MNIST mediante un protocolo común de entrenamiento y prueba.

Específicos:

- Preparar las imágenes de MNIST y reproducir los conjuntos de entrenamiento y prueba.
- Ajustar y evaluar los tres clasificadores con los mismos datos y calcular su exactitud y error en cada conjunto.
- Justificar la elección de un modelo a partir de las métricas de prueba y del análisis de sus errores.

2.2 Modalidad

Práctica en parejas, con ejecución en laboratorio y elaboración del informe fuera de clase.

2.3 Tiempo de duración

Presenciales: 2 horas para preparar los datos, entrenar y evaluar.
No presenciales: 1 hora para comparar resultados y elaborar el informe.

2.4 Instrucciones

Completen los datos de portada y registren los nombres en orden alfabético. Usen Python y conserven un solo cuaderno de trabajo por pareja. Mantengan la misma partición, transformación e hiperparámetros indicados para que los resultados puedan compararse.

Registren el entorno y las versiones de Python y scikit-learn. Completen las tablas con los resultados de su ejecución y numeren las figuras y tablas del informe.

2.5 Listado de equipos, materiales y recursos

Computador con conexión a Internet para la descarga inicial de MNIST [1]. Jupyter Notebook o Google Colab con Python, NumPy, pandas, scikit-learn y Matplotlib.

TAC: Cuaderno interactivo para ejecutar código, visualizar imágenes y documentar los resultados.

2.6 Actividades por desarrollar

Actividad 1. Preparar MNIST. Carguen mnist_784, versión 1 (OpenML, ID 554) [1]. Cada imagen contiene 28 × 28 píxeles en escala de grises y tiene una etiqueta de 0 a 9. Visualicen cinco ejemplos con sus etiquetas.

Conserven la separación original: las primeras 60 000 observaciones pertenecen a entrenamiento y las últimas 10 000 a prueba. Para la práctica, tomen 10 000 y 2 000 observaciones, respectivamente, mediante muestreo estratificado por dígito con semilla 42. El Anexo A proporciona el código de partida.

Representen cada imagen como un vector de 784 intensidades entre 0 y 1, dividiendo por 255. Verifiquen las dimensiones de X_ent y X_pru y reporten cuántos ejemplos de cada dígito quedaron en ambos conjuntos.

Actividad 2. Entrenar. Instancien un objeto para cada modelo con la configuración de la Tabla 1. Apliquen fit(X_ent, y_ent) a los tres, usando exactamente el mismo conjunto de entrenamiento.

Tabla 1. Configuración de los clasificadores

Modelo	Clase de scikit-learn	Hiperparámetros fijados
Árbol de decisión	DecisionTreeClassifier [2]	max_depth=15 random_state=42
Random Forest	RandomForestClassifier [3]	n_estimators=100 max_depth=15 random_state=42
k-NN	KNeighborsClassifier [4]	n_neighbors=5 metric="euclidean" weights="uniform"

Usen los valores por defecto para los demás parámetros. Describan qué hace fit en cada modelo: el árbol aprende reglas de división, el bosque ajusta un conjunto de árboles y k-NN conserva ejemplos de referencia.

Actividad 3. Evaluar. Para cada modelo, apliquen predict a X_ent y a X_pru por separado. Comparen cada predicción con las etiquetas de su propio conjunto. No utilicen las etiquetas de prueba para ajustar ni seleccionar hiperparámetros.

Exactitud (%) = 100 × aciertos / número de ejemplos.
Error de clasificación (%) = 100 × fallos / número de ejemplos = 100 − exactitud (%).

Pueden usar accuracy_score para obtener la proporción de aciertos y multiplicarla por 100 [5]. Calculen la brecha de exactitud como entrenamiento menos prueba, en puntos porcentuales. Redondeen únicamente al reportar.

Actividad 4. Comparar. Construyan una matriz de confusión de prueba por modelo con las clases 0 a 9 en ambos ejes (filas: etiqueta real; columnas: predicción). Usen las métricas y las matrices para sustentar la comparación de la sección 2.7.

2.7 Resultados obtenidos

Registren el número de imágenes por conjunto y su distribución por dígito. Describan el entrenamiento de cada modelo y cómo obtuvieron las predicciones de prueba. Incluyan la configuración utilizada y la versión de scikit-learn.

Tabla 2. Resultados de entrenamiento y prueba

Modelo	Exactitud ent. (%)	Error ent. (%)	Exactitud prueba (%)	Error prueba (%)	Brecha (p. p.)
Árbol de decisión	—	—	—	—	—
Random Forest	—	—	—	—	—
k-NN	—	—	—	—	—

Ent. = entrenamiento. p. p. = puntos porcentuales. Sustituyan los guiones por sus valores con dos decimales. Verifiquen que exactitud y error sumen 100 % en cada conjunto.

Adjunten las tres matrices de confusión en el informe. Para cada modelo, identifiquen la confusión más frecuente entre dos dígitos distintos y reporten cuántos casos hubo. Muestren una imagen de prueba mal clasificada e indiquen la etiqueta real y las tres predicciones.

Respondan en su comparación:

- ¿Qué modelo obtuvo la mayor exactitud y el menor error en prueba? Cuantifiquen la diferencia respecto al segundo, o indiquen si hubo empate.
- ¿Qué modelo presentó la mayor brecha entre entrenamiento y prueba? Expliquen qué sugiere sin tomarla como prueba concluyente de sobreajuste. En k-NN, una observación de entrenamiento puede ser su propio vecino.
- ¿Qué confusión común o diferente observaron entre los modelos? Justifiquen qué clasificador recomendarían para esta tarea con al menos dos evidencias.

2.8 Habilidades blandas empleadas en la práctica

Marquen las habilidades aplicadas y describan una acción concreta que las evidencie.

☐ Liderazgo
☐ Trabajo en equipo
☐ Comunicación asertiva
☐ La empatía
☐ Pensamiento crítico
☐ Flexibilidad
☐ La resolución de conflictos
☐ Adaptabilidad
☐ Responsabilidad

2.9 Conclusiones

Redacten dos conclusiones: una sobre el desempeño en prueba y otra sobre la diferencia entre entrenamiento y prueba. Sustenten ambas con sus resultados.

2.10 Recomendaciones

Propongan una mejora concreta para un ensayo posterior y expliquen cómo comprobarían su efecto sin usar el conjunto de prueba durante el ajuste.

2.11 Referencias bibliográficas

Citen las fuentes utilizadas y agreguen las que consulten, con el formato IEEE.

[1] Y. LeCun, C. Cortes y C. J. C. Burges, «mnist_784», v. 1, OpenML, ID 554. [En línea]. Disponible: Consultar fuente

[2] Scikit-learn developers, «DecisionTreeClassifier», scikit-learn. [En línea]. Disponible: Consultar fuente

[3] Scikit-learn developers, «RandomForestClassifier», scikit-learn. [En línea]. Disponible: Consultar fuente

[4] Scikit-learn developers, «KNeighborsClassifier», scikit-learn. [En línea]. Disponible: Consultar fuente

[5] Scikit-learn developers, «accuracy_score», scikit-learn. [En línea]. Disponible: Consultar fuente

2.12 Anexos

Anexo A. Código de partida para preparar los datos

Copien el bloque al inicio del cuaderno. Completen después la implementación y evaluación de los tres modelos.

```
from sklearn.datasets import fetch_openml
from sklearn.model_selection import train_test_split

X, y = fetch_openml(data_id=554, as_frame=False, return_X_y=True)
X = X.astype("float32") / 255.0
y = y.astype("int64")

def tomar_muestra(X_base, y_base, n):
    X_muestra, _, y_muestra, _ = train_test_split(
        X_base, y_base, train_size=n, stratify=y_base,
        random_state=42
    )
    return X_muestra, y_muestra

X_ent, y_ent = tomar_muestra(X[:60000], y[:60000], 10000)
X_pru, y_pru = tomar_muestra(X[60000:], y[60000:], 2000)
print(X_ent.shape, X_pru.shape)  # (10000, 784), (2000, 784)
```

Anexo B. Archivos para la entrega

- Informe en Word, con la Tabla 2, las matrices de confusión, la comparación y las conclusiones.
- Cuaderno .ipynb ejecutado, con código y salidas de los tres modelos. Debe poder ejecutarse desde la carga de MNIST hasta el cálculo de las métricas.

Suban ambos archivos a la actividad del aula virtual. Identifiquen los archivos con los apellidos de los integrantes.